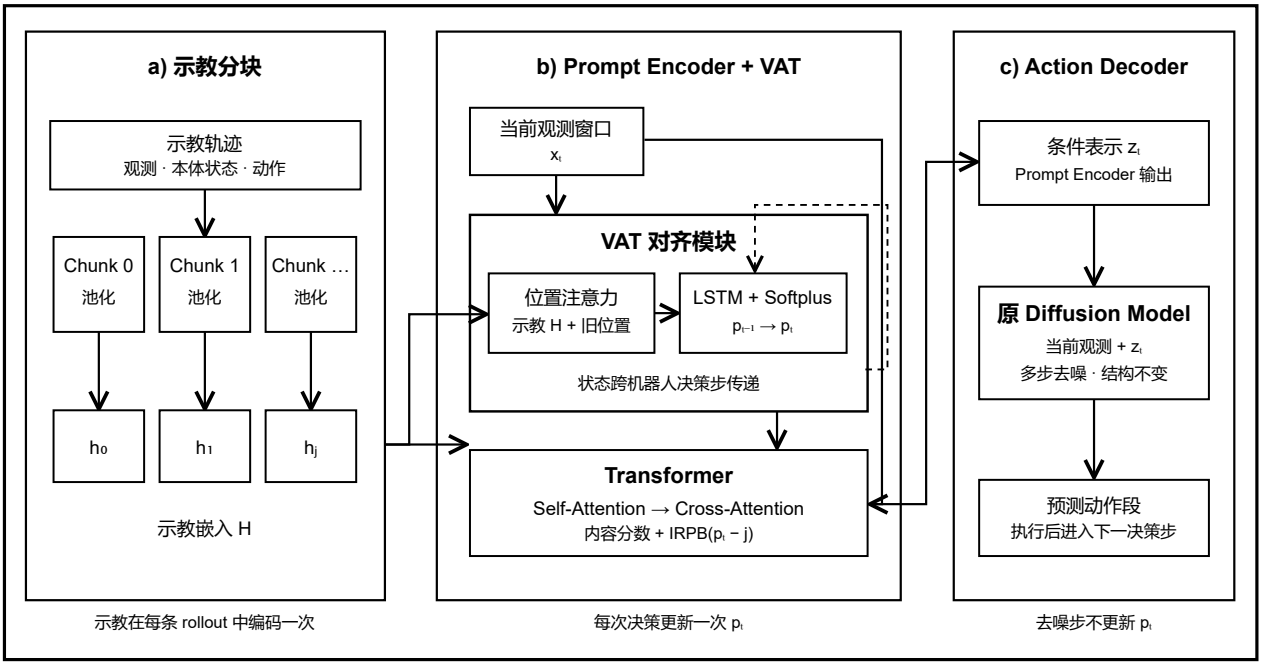
BPP + VAT 实验方案

1. 目标

结合 VAT 算法改进 BPP 的 Prompt Encoder：利用单调位置对齐与可微相对偏置（IRPB）约束 Cross-Attention，根除示教学习中的轨迹回溯与死循环缺陷。

2. 总流程



3. 算法定义

h_j 是第 j 个示教片段的编码，p_t 是机器人第 t 次决策时对齐到的示教位置，x_t 是当前观测窗口的表示。p_t 与示教片段 h_j 使用不同符号。

3.1 对齐位置更新

对齐位置的初始值默认为0；p_t 是第 t 次决策在示教中的位置，由上一位置加本次前进步长得到。

$$p_0 = 0, \qquad p_t = p_{t-1} + \Delta p_t \quad (t \geq 1), \qquad \Delta p_t = \mathrm{softplus}(w^\top u_t + b) > 0.$$

u_t 是 LSTM 隐藏状态。模型先根据旧位置读出附近的示教内容 g_t，再结合当前观测 x_t 更新状态并算出步长。

$$a_{t,j}^{(k)} = \mathrm{softmax}_j\left(\beta_{\mathrm{align}}^{(k)}(p_{t-1} - j)\right), \quad g_t = \mathrm{Concat}_k\left(\sum_{j=0}^{N-1} a_{t,j}^{(k)} h_j\right), \quad (u_t, c_t) = \mathrm{LSTM}([x_t, g_t], (u_{t-1}, c_{t-1})).$$

3.2 插值相对位置偏置（IRPB）

计算示教片段到 p_t 的距离，并在相邻分桶间插值，得到对 p_t 可微的位置偏置。

$$d_{t,j} = p_t - j, \qquad \beta^{(\ell,k)}(d_{t,j}) = (1-r)\, b^{(\ell,k)}_{\mathrm{sgn}(\eta)m} + r\, b^{(\ell,k)}_{\mathrm{sgn}(\eta)(m+1)}.$$

η 是距离对应的连续分桶位置，m 是左侧分桶，r 是插值权重；近距离分桶细，远距离分桶粗。

$$\eta = f(d_{t,j}), \qquad m = \lfloor |\eta| \rfloor, \qquad r = |\eta| - m.$$

$$f(d) = \begin{cases} d, & 0 \le d < B/2, \\ B/2 + \dfrac{\log(d/(B/2))}{\log(D/(B/2))}(B/2-1), & B/2 \le d < D, \\ B-1, & d \ge D, \\ -f(-d), & d < 0. \end{cases}$$

B 是每侧的分桶数量，D 是最大分桶距离；$b^{(\ell,k)}$ 是第 ℓ 层、第 k 个注意力头的偏置表。到达末桶时只读取末桶。

3.3 远距离惩罚

在 3.2 得到的插值偏置上扣除超出 D 的距离惩罚，得到最终位置偏置 $\tilde{\beta}$。

$$\tilde{\beta}^{(\ell,k)}(d) = \beta^{(\ell,k)}(d) - \lambda_{\mathrm{MD}} \max(|d| - D, 0).$$

偏置表以当前位置附近更高的高斯形状初始化；λ_{MD} 决定远距离惩罚强度。

3.4 Prompt Encoder 的 Cross-Attention

把 3.3 得到的最终偏置加到 BPP 的内容匹配分数上，计算当前观测对示教片段的注意力。

$$s_{t,i,j}^{(\ell,k)} = \frac{q_{t,i}^{(\ell,k)} \cdot k_j^{(\ell,k)}}{\sqrt{d_k}} + \tilde{\beta}^{(\ell,k)}(p_t - j).$$

$\alpha_{t,i,j}^{(\ell,k)}$ 是归一化后的注意力权重；Prompt Encoder 据此输出给 Diffusion Model 的条件表示 z_t。

$$\alpha_{t,i,j}^{(\ell,k)} = \mathrm{softmax}_j\left(s_{t,i,j}^{(\ell,k)} + M_j\right), \qquad z_t = \mathrm{PromptEncoder}(x_t, H, p_t).$$

i 是当前观测 token，j 是示教片段，M_j 是 padding mask。示教分块池化、Prompt Encoder 的 self-attention 和 Diffusion Model 的网络结构保持原样。

3.5 动作生成与训练损失

Diffusion Model 在每次机器人决策中固定使用同一个 z_t，并用 BPP 原有的噪声预测损失联合训练全部模块。

$$L_{\mathrm{diff}} = E_{t,\tau,\epsilon}\left[\left\| \epsilon - \epsilon_\theta\left(A_t^{(\tau)}, \tau, x_t, z_t\right)\right\|_2^2\right].$$

z_t 每次决策产生一次；Diffusion Model 的去噪步不更新 p_t。

4. 备注

p_t 单调递增，为 Cross-Attention 提供随决策步向前移动的位置参考；最终注意力仍由内容匹配与位置偏置共同决定。因此，这一机制不能保证完全消除回溯或死循环：模型仍可能在 p_t 附近反复关注相近的示教片段，也可能在内容匹配足够强时关注更早的片段。

5. 训练方式

主实验选择端到端联合训练。VAT 对齐模块、BPP Prompt Encoder 和原 Diffusion Model 一起接受 diffusion loss 的梯度。Diffusion Model 的结构与损失不改，但参数继续训练。

1. 先运行原 BPP，作为同数据、同任务划分下的对照。
2. 沿用可复用的 BPP 权重；新加入的 LSTM 和 IRPB 单独初始化。
3. 用连续轨迹窗口训练 VAT 状态递推；窗口内保留跨决策步梯度。长窗口可使用截断反向传播。
4. 每个决策步的 z_t 连接到原 Diffusion Model，中间不截断梯度。

冻结 Diffusion Model 并单独训练 VAT 不是主实验：VAT 没有直接的位置标签，而原 Diffusion Model 也需要适应新的条件表示。